## retoempleados

May 12, 2024

## 1 Sección nueva

```
[192]: !pip install panda
       !pip install request
       from google.colab import drive
       drive.mount('/content/drive')
       import numpy as np
       import pandas as pd
       EmpleadosAttrition0 = pd.read_csv("/content/drive/MyDrive/EmpleadosAttrition.
        ⇔csv")
       EmpleadosAttritionO
       EmpleadosAttrition0= EmpleadosAttrition0.
        →drop(['EmployeeCount', 'EmployeeNumber', 'Over18', 'StandardHours'], axis=1)
       EmpleadosAttrition0
       #se suman los años del empleado
       EmpleadosAttrition['HiringDate']
       type(EmpleadosAttrition['HiringDate'])
       EmpleadosAttritionO['año'] = EmpleadosAttritionO['HiringDate'].str[-4:].
        ⇔astype(int)
       EmpleadosAttritionO
       EmpleadosAttritionO['año'] = 2024 - EmpleadosAttritionO['año']
       EmpleadosAttrition0
       #Se crea variable year
       EmpleadosAttrition0 = EmpleadosAttrition0.rename(columns={'año':'Year'})
       {\tt EmpleadosAttrition0}
       #Se crea variable YearsAtCompany
       #No entendi como quitarle a 2018 el Year que esta en entero
```

```
EmpleadosAttritionO['YearsAtCompany'] = 2018 -__
   → Empleados Attrition O['Hiring Date'].str[-4:].astype(int)
EmpleadosAttritionO
#Convertir variable DistanceFromHomea a entera
EmpleadosAttritionO['DistanceFromHome_km']=EmpleadosAttritionO['DistanceFromHome'].
   ⇔str.split(pat=' ').str[0]
{\tt EmpleadosAttrition0}
#Quitar variables Year, HiringDate, DistanceFromHome
{\tt EmpleadosAttrition0=EmpleadosAttrition0.}
   →drop(['HiringDate','Year','DistanceFromHome'],axis=1)
EmpleadosAttrition0
#Generar un nuevo frame
SueldoPromedioDepto = EmpleadosAttritionO[['Department','MonthlyIncome']]
{\tt SueldoPromedioDepto}
SueldoPromedio= SueldoPromedioDepto.groupby(['Department'])[['MonthlyIncome']].
   →mean()
SueldoPromedio
#Escalar la variable MonthlyIncome
EmpleadosAttritionO['MonthlyIncomeNorm'] = (EmpleadosAttritionO['MonthlyIncome'] - min(EmpleadosAttritionO['MonthlyIncome'] - min(EmpleadosAttritionO['Mon
   →(max(EmpleadosAttrition0['MonthlyIncome'])-min(EmpleadosAttrition0['MonthlyIncome']))
EmpleadosAttritionO
#Convertir categoricas en numericas
#No me convierte por el metodo get_dummies(solo muestra False y True)
#LO QUE ARROJA SON ARREGLOS Y AL METERLOS COMO UNA COLUMNA GENERA EN EL FRAMEL
  →ORIGINAL SOLO INCLUYE 1
from sklearn.preprocessing import LabelBinarizer
from sklearn.preprocessing import OneHotEncoder
BT=pd.get_dummies(EmpleadosAttritionO.BusinessTravel,prefix='BusinessTravel')
BT1=LabelBinarizer().fit_transform(EmpleadosAttritionO.BusinessTravel)
BT1
```

```
BT2=OneHotEncoder().fit_transform(EmpleadosAttritionO[['BusinessTravel']]).
 →toarray()
BT2
DPT=pd.get_dummies(EmpleadosAttritionO.Department,prefix='Department')
DPT
DPT1=LabelBinarizer().fit transform(EmpleadosAttritionO.Department)
DPT2=OneHotEncoder().fit_transform(EmpleadosAttritionO[['BusinessTravel']]).
 →toarray()
DPT2
EDU=pd.get dummies(EmpleadosAttritionO.EducationField,prefix='Education')
EDU
EDU1=LabelBinarizer().fit_transform(EmpleadosAttritionO.EducationField)
EDU2=OneHotEncoder().fit_transform(EmpleadosAttritionO[['EducationField']]).
 →toarray()
EDU2
GEN=pd.get_dummies(EmpleadosAttritionO.Gender,prefix='Gender')
GEN
GEN1=LabelBinarizer().fit transform(EmpleadosAttritionO.Gender)
GEN1
GEN2=OneHotEncoder().fit transform(EmpleadosAttritionO[['Gender']]).toarray()
GEN2
job=pd.get_dummies(EmpleadosAttritionO.JobRole,prefix='Job')
job1=LabelBinarizer().fit_transform(EmpleadosAttritionO.JobRole)
job2=OneHotEncoder().fit_transform(EmpleadosAttritionO[['JobRole']]).toarray()
job2
mar=pd.get dummies(EmpleadosAttritionO.MaritalStatus,prefix='Mar')
mar1=LabelBinarizer().fit_transform(EmpleadosAttritionO.MaritalStatus)
mar2=OneHotEncoder().fit_transform(EmpleadosAttritionO[['MaritalStatus']]).
 →toarray()
mar2
```

```
attri=pd.get_dummies(EmpleadosAttritionO.Attrition,prefix='Attri')
attri
attri1=LabelBinarizer().fit_transform(EmpleadosAttrition0.Attrition)
attri1
attri2=OneHotEncoder().fit_transform(EmpleadosAttritionO[['Attrition']]).
 →toarray()
attri2
EmpleadosAttritionO['BusinessTravel']=BT2
EmpleadosAttritionO['Department']=DPT2
EmpleadosAttritionO['EducationField']=EDU2
EmpleadosAttritionO['Gender']=GEN2
EmpleadosAttritionO['JobRole']=job2
EmpleadosAttritionO['MaritalStatus']=mar2
EmpleadosAttrition0['Attrition'] = attri2
EmpleadosAttrition0
#calcular correlacion lineal
EmpleadosAttritionO['Age'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['BusinessTravel'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['Department'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttrition0['Education'].corr(EmpleadosAttrition0['Attrition'])
EmpleadosAttritionO['EducationField'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['EnvironmentSatisfaction'].

¬corr(EmpleadosAttrition0['Attrition'])
EmpleadosAttrition0['Gender'].corr(EmpleadosAttrition0['Attrition'])
EmpleadosAttritionO['JobInvolvement'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['JobLevel'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['JobRole'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['JobSatisfaction'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['MaritalStatus'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['MonthlyIncome'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttrition0['NumCompaniesWorked'].corr(EmpleadosAttrition0['Attrition'])
EmpleadosAttritionO['PerformanceRating'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['RelationshipSatisfaction'].
 EmpleadosAttritionO['StandardHours'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['TotalWorkingYears'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['TrainingTimesLastYear'].
 ⇔corr(EmpleadosAttrition0['Attrition'])
EmpleadosAttritionO['WorkLifeBalance'].corr(EmpleadosAttritionO['Attrition'])
```

```
EmpleadosAttritionO['YearsInCurrentRole'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO['YearsSinceLastPromotion'].

¬corr(EmpleadosAttrition0['Attrition'])
EmpleadosAttrition0['YearsAtCompany'].corr(EmpleadosAttrition0['Attrition'])
EmpleadosAttritionO['DistanceFromHome_km'].
 ⇔corr(EmpleadosAttrition0['Attrition'])
EmpleadosAttritionO['MonthlyIncomeNorm'].corr(EmpleadosAttritionO['Attrition'])
EmpleadosAttritionO.corr()
#Seleccionar solo las que tienen arriba de 0.1
#age, environment satisfaction, job involvement, job level, job satisfaction, ⊔
⇔marital status,
# monthly income, total working years, years in current role, years at company,
 ⇔monthly income norm
EmpleadosAttritionFinal =_
 -EmpleadosAttritionO[['Age','EnvironmentSatisfaction','JobInvolvement','JobLeve1','JobSatisf
EmpleadosAttritionFinal
#Crear nueva variable EmpleadosAttritionPCA
from sklearn.decomposition import PCA
EmpleadosAttritionFinal
pca= PCA(4)
pca.fit(EmpleadosAttritionFinal)
print(pca.components_)
print(pca.explained_variance_)
print(pca.explained_variance_ratio_)
EmpleadosAttritionPCA=pca.transform(EmpleadosAttritionFinal)
{\tt EmpleadosAttritionPCA}
#Agregar CP al frame EmpleadosAttritionFinal
#No entendi como hacerle, porfavor necesito un poco de ayuda aqui
EmpleadosAttritionPCA[:,0]
EmpleadosAttritionPCA[:,1]
EmpleadosAttritionPCA[:,2]
EmpleadosAttritionPCA[:,3]
EmpleadosAttritionFinal = EmpleadosAttritionPCA.assign(CP=['CO','C1','C2''C3'])
```

```
#Guardar datos

EmpleadosAttritionFinal.to_csv("EmpleadosAttritionFinal.csv", index = False, usep = ' ')
```